FLOODLAB · PREDICT THE FLOOD

多元線性回歸、特徵選擇與洪水機率預測

Kaggle Playground Series S4E5 · HW2 最終報告

課程	物聯網應用與資料分析
學號	5115056040
姓名	蕭程勻
日期	2026-10-21

Repository

https://github.com/AidenXiao0924/HW2-Predict-the-Flood

GitHub Pages

https://aidenxiao0924.github.io/HW2-Predict-the-Flood/

本報告所有模型分數與圖表均來自專案實際程式執行；未提交 Kaggle leaderboard，故不宣稱競賽排名。

摘要

本研究使用 Kaggle Playground Series S4E5「Predict the Flood」資料集，以 20 個數值特徵預測連續目標 FloodProbability。資料共 1,117,957 筆有標籤樣本，以固定亂數種子 42 分成 64% training、16% validation 與 20% final holdout。候選模型在 training-only 固定 200,000 筆樣本上進行 5-fold CV，比較 OLS、SelectKBest、RFE、Ridge 與 Lasso。CV 選出的 Ridge（alpha=10）在 final holdout 的 RMSE 為 0.020080、MAE 為 0.015793、R^2 為 0.844877、Adjusted R^2 為 0.844863。全特徵 OLS 表現幾乎相同，並另外用於回歸假設診斷與 95% 信賴 / 預測區間。研究結果是競賽資料中的統計關聯，不代表真實洪水預警或因果效果。

關鍵字：Multiple Linear Regression、Ridge、Feature Selection、CRISP-DM、Prediction Interval

實驗設計一覽

項目	設定
資料	train.csv：1,117,957 × 22；20 features + id + target
切分	64% training / 16% validation / 20% final holdout
選模	training-only 200,000 rows、5-fold CV、CV RMSE
最終重訓	完整 80% development data
最佳模型	Ridge（alpha=10）

1. CRISP-DM：Business Understanding

目標是以資料中的 20 個數值欄位預測 FloodProbability。成功標準以 CV RMSE 為主要選模依據，並完整報告 MAE、MSE、RMSE、R^2 與 Adjusted R^2。此資料是 Kaggle Playground 競賽資料，目標名稱雖含 probability，仍不可直接當成現實世界校準過的洪水機率。模型係數只表示關聯，不構成因果推論。

2. CRISP-DM：Data Understanding

- train.csv 共 1,117,957 筆、22 欄；competition test 共 745,305 筆。
- 20 個輸入特徵皆為數值型；另有唯一識別碼 id 與目標 FloodProbability。
- 本次檢查無缺失值；target 範圍 0.285 至 0.725，中位數 0.505。
- 單一特徵與目標的相關係數約 0.178 至 0.190，訊號分散在多個特徵。

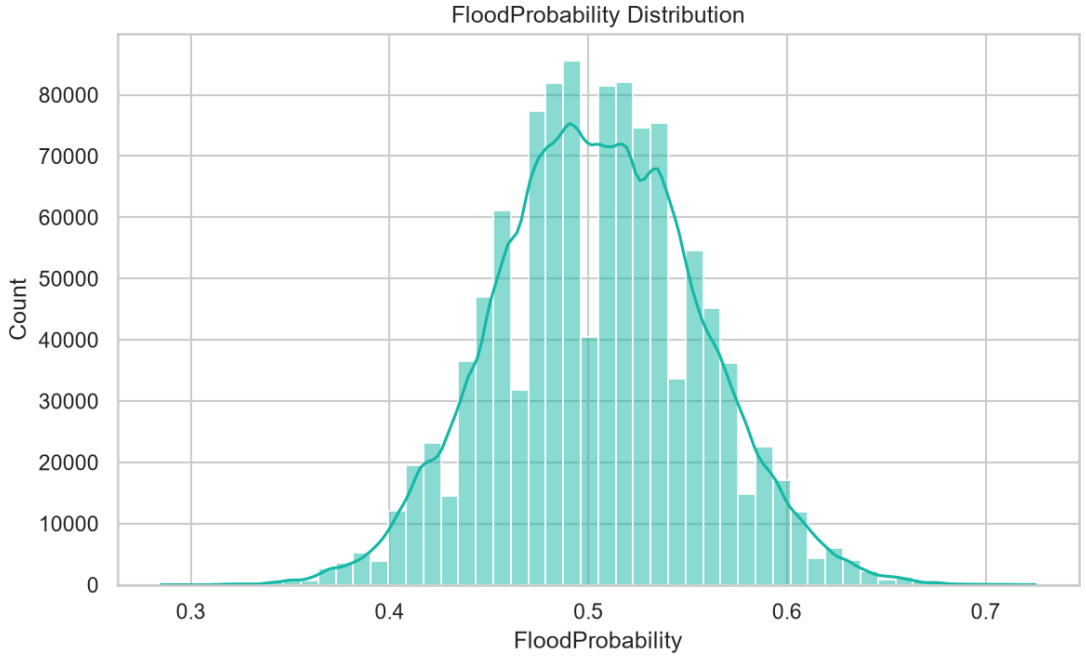


圖 1 FloodProbability 分布（由真實 train.csv 產生）

2.1 二十個輸入特徵

#	特徵	#	特徵
1	MonsoonIntensity	11	IneffectiveDisasterPreparedness
2	TopographyDrainage	12	DrainageSystems
3	RiverManagement	13	CoastalVulnerability
4	Deforestation	14	Landslides
5	Urbanization	15	Watersheds
6	ClimateChange	16	DeterioratingInfrastructure
7	DamsQuality	17	PopulationScore
8	Siltation	18	WetlandLoss
9	AgriculturalPractices	19	InadequatePlanning
10	Encroachments	20	PoliticalFactors

id 僅用於識別，不進入模型；FloodProbability 是預測目標。欄位名稱代表競賽設計的概念分數，報告不將其重新解釋為實際量測單位。

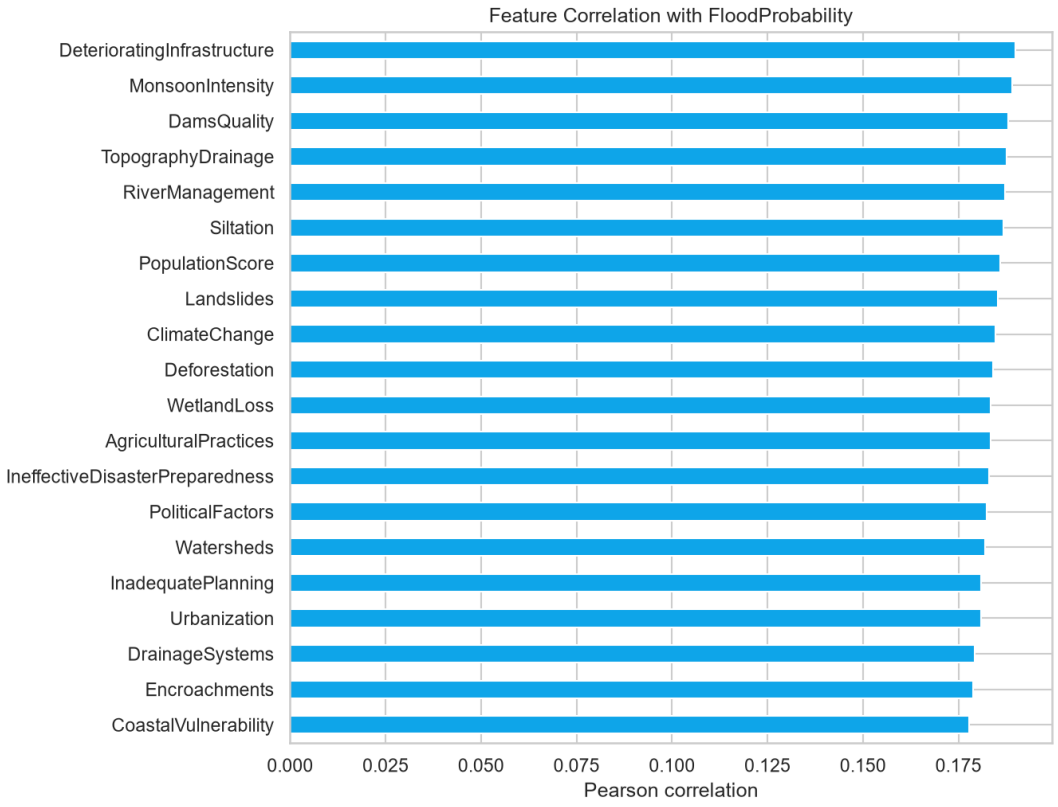


圖 2 各特徵與目標的 Pearson 相關排序

2.2 特徵相關結構

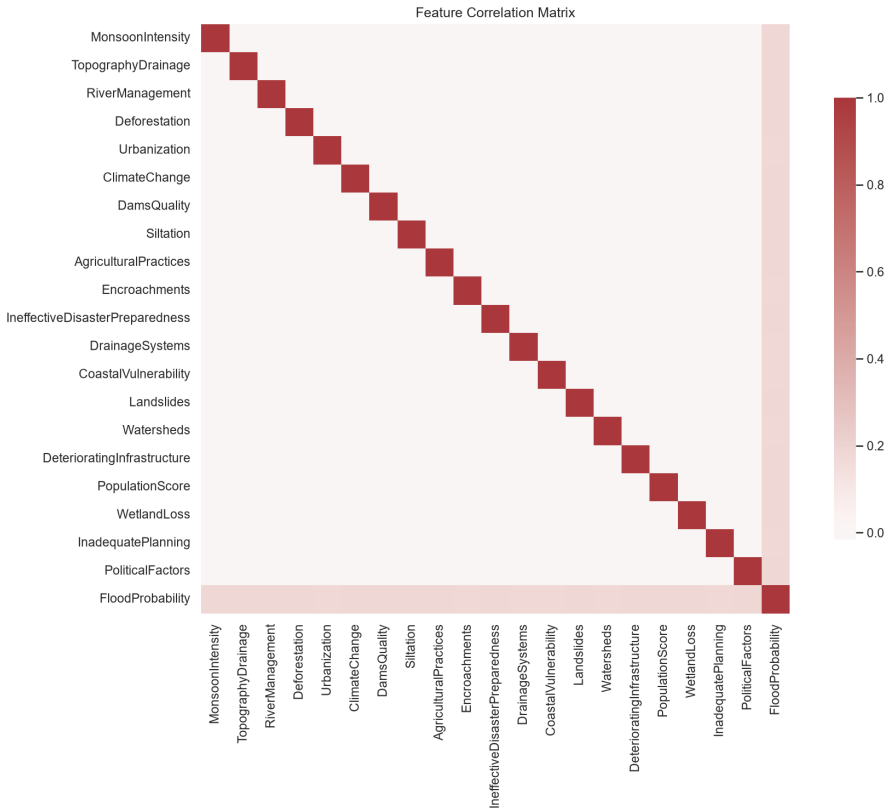


圖 3 20 個特徵與目標的相關矩陣

各特徵 VIF 最大值為 1.00367，未見明顯多重共線性。然而 VIF 低不代表誤差同方差或常態性成立，仍須分別診斷。

3. CRISP-DM：Data Preparation

- 以 random_state=42 固定結果；先保留 20% final holdout，再把其餘資料分成 64% training 與 16% validation。
- id 與 target 從特徵矩陣排除；官方 competition test 沒有真實 target，不用於計算 R^2。
- SimpleImputer、StandardScaler、SelectKBest 與 RFE 放入 sklearn Pipeline，僅在各 training fold 內 fit，避免資料洩漏。
- 候選模型的 5-fold CV 使用 training-only 固定 200,000 筆抽樣；選模後以完整 80% development data 重訓，final holdout 只作最後一次評估。

4. CRISP-DM：Modeling

模型	設定	目的
Dummy Mean	平均值預測	無資訊基準
OLS	全部 20 特徵	主要線性回歸與統計診斷
SelectKBest + OLS	f_regression，k=1..20	單變量篩選
RFE + OLS	k=5、10、15、20	遞迴消除特徵
Ridge	alpha=0.01、0.1、1、10、100	L2 正則化
Lasso	alpha=0.0001、0.001、0.005、0.01	L1 正則化與稀疏化

Ridge 的 L2 懲罰可縮小並穩定係數，但本資料 VIF 原本已很低，因此 Ridge 與 OLS 預測幾乎一致。OLS 的 p-value、VIF 與解析式區間不能直接套用到 Ridge。

4.1 特徵選擇與交叉驗證比較

模型	特徵數	CV RMSE	Validation RMSE
Ridge alpha=10	20	0.0200766	0.0200757
OLS all	20	0.0200766	0.0200757
SelectKBest k=20	20	0.0200766	0.0200757
RFE k=20	20	0.0200766	0.0200757
Lasso alpha=0.0001	20	0.0200828	0.0200856
SelectKBest k=10	10	0.0402423	0.0403162
RFE k=10	10	0.0403996	0.0403864
Dummy Mean	0	0.0510754	0.0510959

全 20 特徵模型的 CV RMSE 最低且彼此極接近。SelectKBest 或 RFE 減至 10 個特徵時，CV RMSE 約增加到 0.040；表示訊號分散於多個欄位。Ridge alpha=10 以最小的 CV RMSE 被選中，差距非常小，實務上應解讀為與 OLS 同一表現層級。

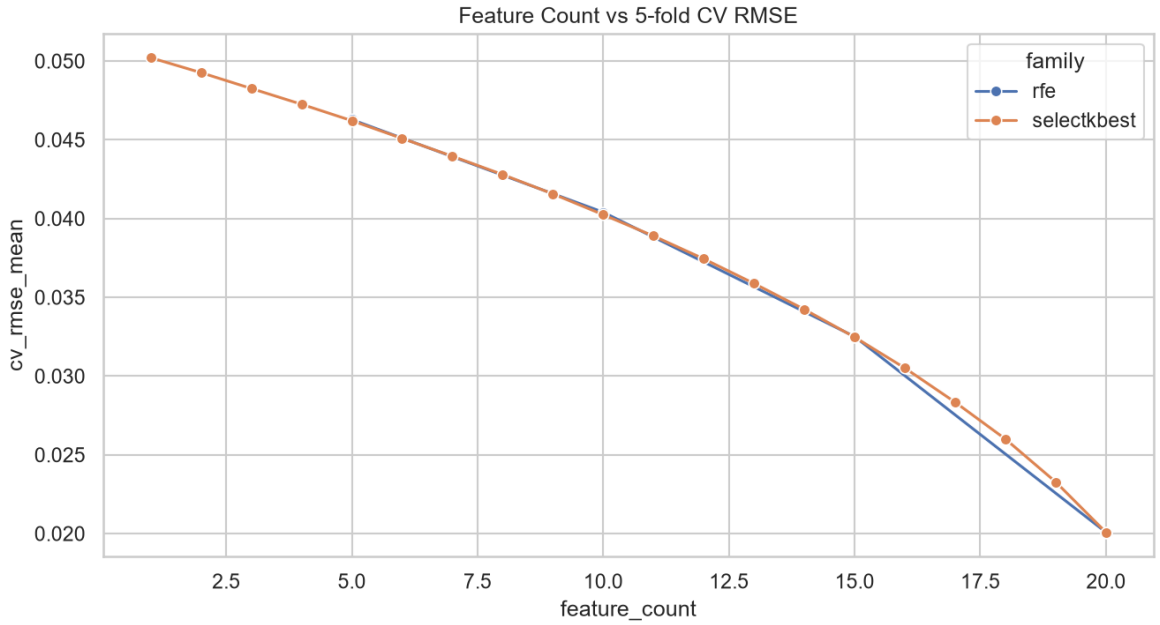


圖 4 特徵數與交叉驗證表現

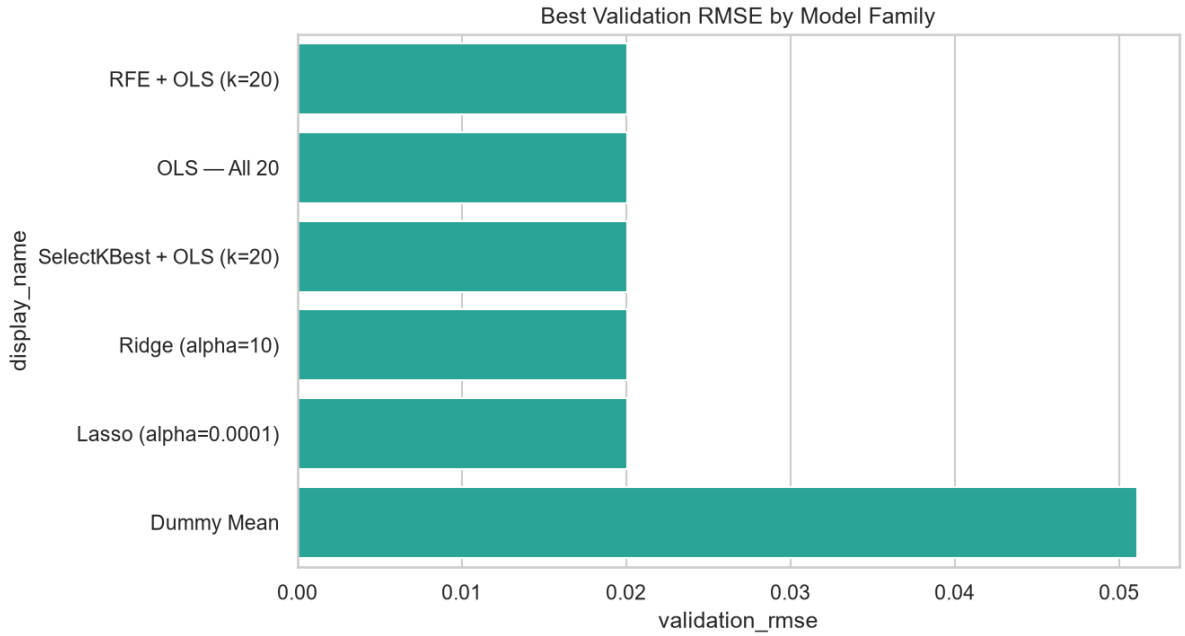


圖 5 候選模型比較（同一 CV 設定）

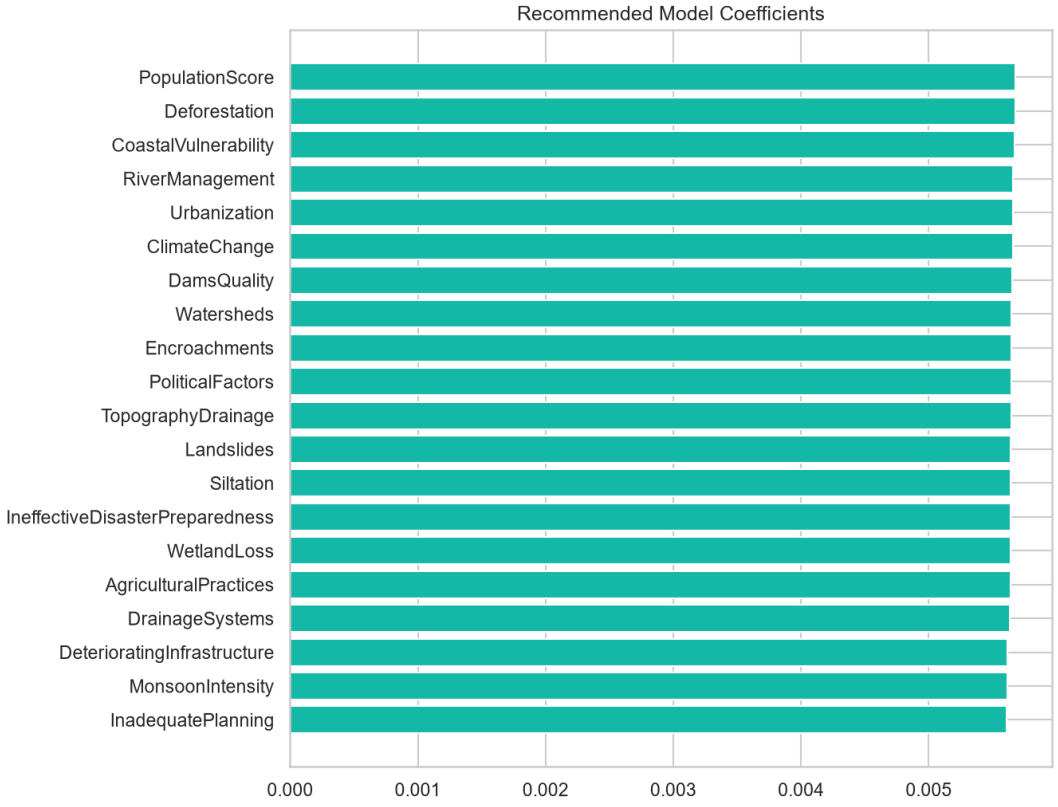


圖 6 全特徵線性模型係數

5. CRISP-DM：Evaluation

推薦模型 Ridge（alpha=10）與全 20 特徵 OLS 的 final holdout 結果如下。兩者差異小於顯示位數；最終推薦 Ridge 是依事先設定的 CV RMSE 規則，而非使用 holdout 反覆挑選。

模型	MAE	MSE	RMSE	R^2	Adjusted R^2
Ridge alpha=10	0.0157925	0.000403207	0.0200800	0.844877	0.844863
OLS all	0.0157925	0.000403207	0.0200800	0.844877	0.844863

指標定義

- MAE：平均絕對誤差，與 target 同尺度。
- MSE：平方誤差平均，對大誤差較敏感。
- RMSE：MSE 開根號，回到 target 尺度；本專案用於 CV 選模。
- R^2：模型相對於平均值基準所解釋的變異比例。
- Adjusted R^2：依樣本數 n 與特徵數 p 修正 R^2，公式為 $1-(1-R^2)(n-1)/(n-p-1)$。

5.1 OLS 回歸假設與殘差診斷

檢查	實際結果	解讀
線性 / 殘差圖	見圖 7	殘差整體以 0 為中心，但仍需搭配異質變異檢定
Durbin-Watson	1.99885	未見明顯一階自相關；資料非時間序列，解讀有限
Breusch-Pagan	$p < 0.001$	拒絕同方差；大樣本會放大微小偏離
Jarque-Bera	$p < 0.001$	殘差不完全常態；skew=0.6946、excess kurtosis=1.0898
VIF	max=1.00367	未見明顯多重共線性

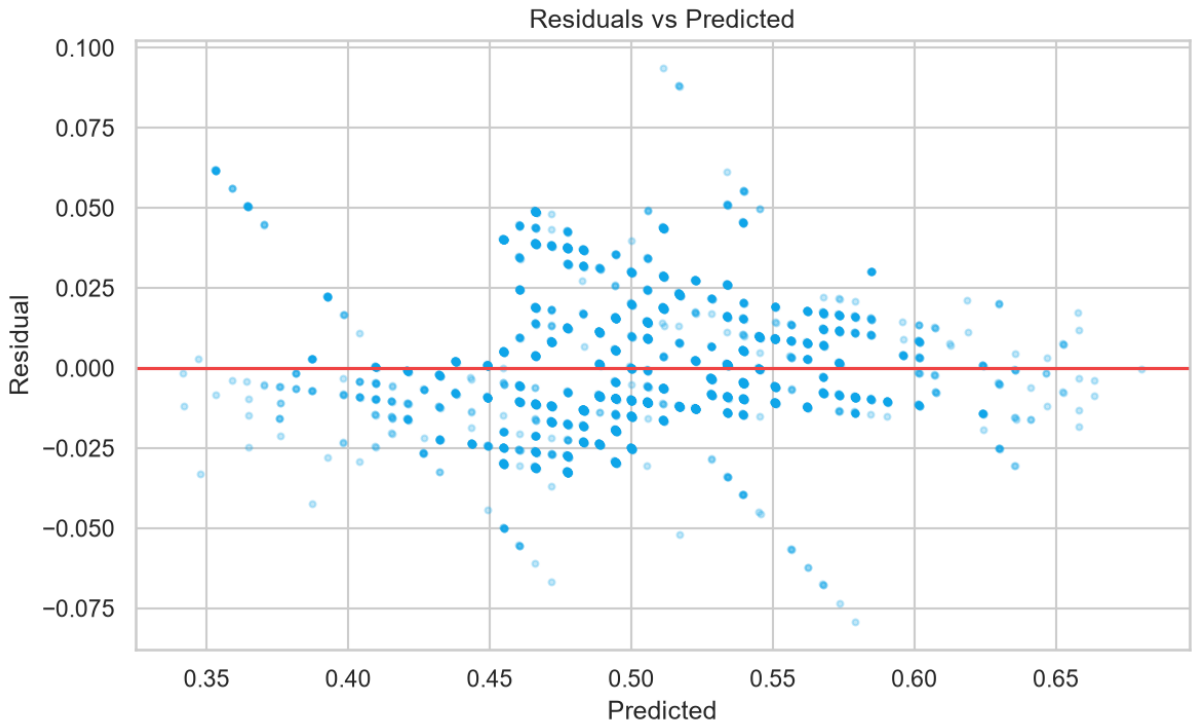


圖 7 OLS 殘差對預測值

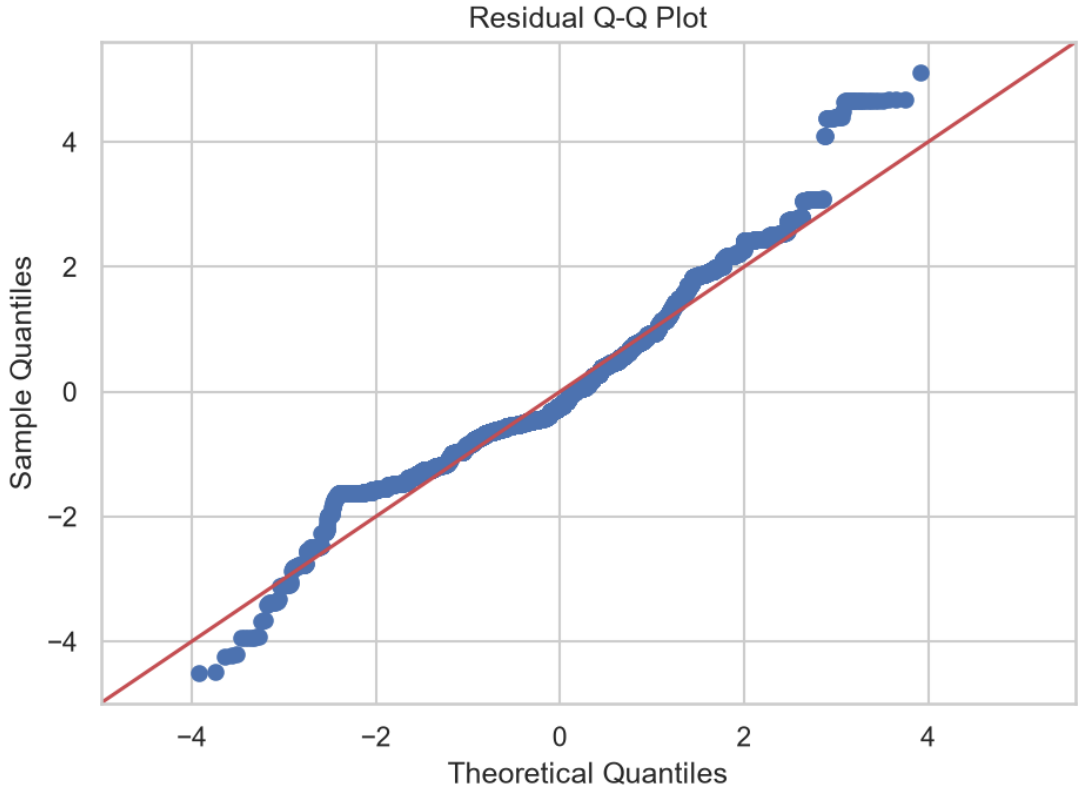


圖 8 OLS 殘差 Q-Q 圖

5.2 OLS 95% 信賴區間與預測區間

statsmodels OLS 的平均反應 95% 信賴區間（confidence interval, CI）描述在指定特徵下平均預測值的不確定性；單筆觀測 95% 預測區間（prediction interval, PI）還包含個別誤差，因此較寬。本次 final holdout 的 PI coverage 為 94.61%，平均寬度為 0.07877。該區間只屬於 OLS 診斷，未冒用為 Ridge 的解析區間。

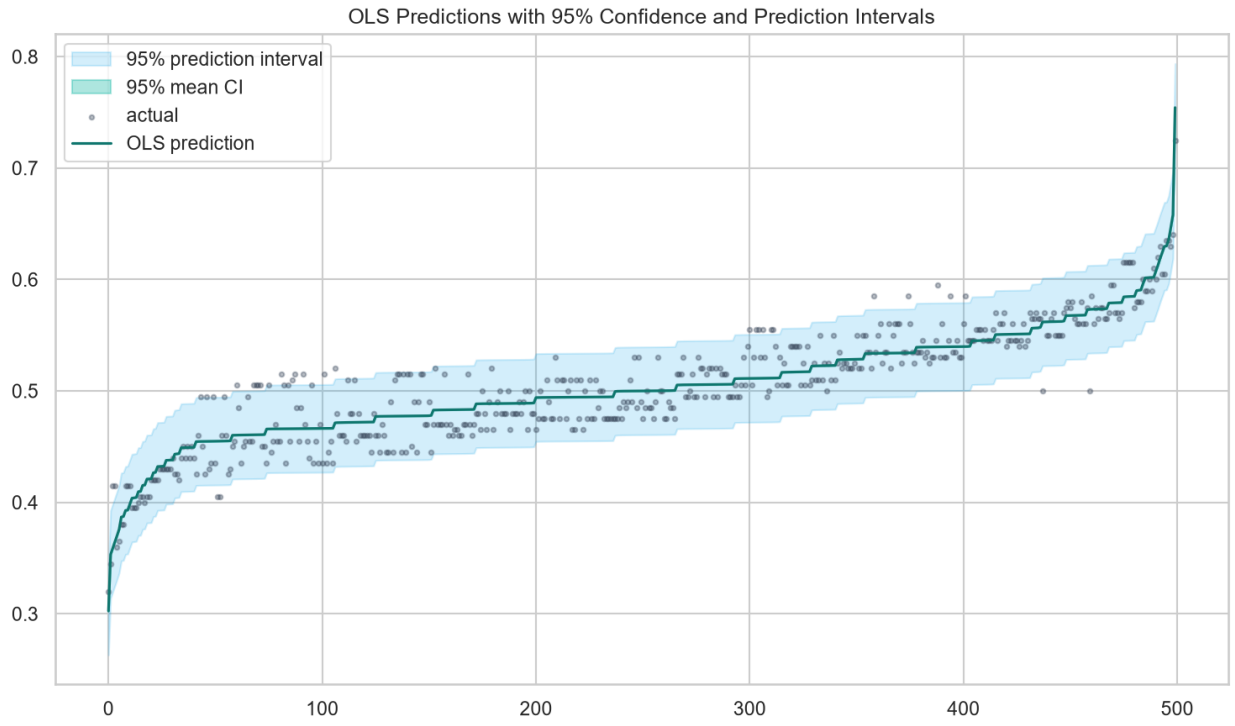


圖 9 OLS 預測值、95% 平均反應信賴區間與單筆預測區間

限制：coverage 是特定資料切分上的經驗比例；BP 與 JB 檢定顯示理想假設並未完全成立，因此區間應視為課堂上的 OLS 推論示範，而非現實災害風險保證。

6. CRISP-DM：Deployment

- Python 將模型係數、評估結果、圖表點與少量真實樣本匯出為 compact JSON/CSV；網站不下載百萬筆原始資料。
- What-If simulator 使用 Ridge 匯出的原始尺度係數計算，並以自動化測試確認 Python/JavaScript 預測一致。
- 網站以 HTML/CSS/Vanilla JavaScript 與 Chart.js 建置，由 GitHub Actions 發布 web/ 至 GitHub Pages。
- Ridge 頁面不顯示 OLS 的解析式 CI/PI；區間只呈現在 OLS diagnostics。



圖 10 FloodLab GitHub Pages Dashboard 首頁截圖

Repository：https://github.com/AidenXiao0924/HW2-Predict-the-Flood

Pages：https://aidenxiao0924.github.io/HW2-Predict-the-Flood/

7. NotebookLM 研究摘要

（經整理與校訂；原始匯出檔另行保留）

本研究以 NotebookLM 彙整 Kaggle Playground Series S4E5「Predict the Flood」的公開解法，並與本次 HW2 實驗分開討論。本次實驗使用 1,117,957 筆有標籤資料與 20 個數值特徵，在固定 random_state=42 的 64/16/20 切分下，比較 OLS、SelectKBest、RFE、Ridge 與 Lasso；模型以 training-only 的 200,000 筆樣本進行 5-fold CV，最後由 Ridge（alpha=10）在獨立 holdout 得到 R^2 0.844877、RMSE 0.020080 [1,2]。OLS 的預測表現近似，另用於 VIF、殘差檢定及 95% 平均反應信賴區間與單筆觀測預測區間；這些統計推論不應視為 Ridge 的解析結果 [1]。外部資料指出，Linear Regression 與 CatBoost 在原始特徵上的表現接近 [3,4]，另有研究報告神經迴歸及競賽高分方案可達較高分數 [5,6]。然而外部結果可能來自不同 CV、holdout 或 Kaggle leaderboard，不能與本次 holdout 分數直接排序。列級統計特徵、非線性模型與 ensemble 是合理的後續實驗方向 [7, 8]，但現有資料不足以斷言單一技巧就是領先成績的唯一原因。此比較著重方法、成本與可解釋性，不把異質評估數字當成同一競賽名次。整體而言，本次線性模型提供可重現、低成本且具統計解釋性的課堂基準；若追求競賽分數，仍需在一致驗證設計下另行測試特徵工程與複雜模型。

7.1 外部方法比較

方法 / 來源	來源報告內容	與本次 Ridge 的正確比較方式
Linear / CatBoost [3,4]	外部測試或 CV 約 0.845，CatBoost略高	設定不同，只能說明兩類模型在公開實作中接近
NIAQUE [5]	外部研究報告 S4E5 R^2 0.867	不是本次 holdout；可視為高成本非線性候選
AutoGluon / ensemble [6]	彙整頁記錄領先 S4E5 方案	不能由彙整頁單獨歸因於某一特徵技巧
Row statistics / boosting [7,8]	公開指南與實作建議的方向	需在相同 folds 中作消融實驗後才能下結論

研究結論

- 本次 OLS/Ridge 是低成本、可重現且符合課堂多元線性回歸要求的強基準。
- 外部 leaderboard、CV 與本次 holdout 不可直接比較，也不能由數字差異宣稱統計顯著。
- 後續可在相同 Pipeline 與 folds 中加入 row sum/mean/std、GBDT 或 ensemble，再做消融比較。
- OLS 診斷與 CI/PI 屬於 OLS；Ridge 正則化不等同於 OLS 統計推論。

8. GPT 輔助內容

GPT/Codex 協助環境檢查、程式架構、資料驗證、模型 Pipeline、測試、互動網站、NotebookLM 文字校訂與報告排版。模型分數、表格與圖表均由本機 Python 對真實 Kaggle CSV 實際執行產生。GPT 未代替使用者宣稱完成 NotebookLM 研究，也未虛構 Kaggle 提交、排名或對話紀錄。

9. 限制與結論

- CV 使用 training-only 固定 200,000 筆抽樣以控制運算成本；最終模型仍以完整 80% development data 重訓。
- 線性模型不能捕捉所有非線性與交互作用。
- BP/JB 在百萬級樣本下對微小偏離敏感，應搭配圖形與實務差異解讀。
- 官方 competition test 無標籤且本專案未提交 Kaggle，因此沒有可宣稱的 leaderboard 分數或排名。

本次結果顯示，20 個特徵共同提供近似線性累加訊號。Ridge 與 OLS 均得到約 0.8449 的 holdout R^2；特徵大幅刪減會明顯降低預測力。Ridge 適合作為穩定部署模型，OLS 則提供本課程要求的統計診斷與區間估計。

參考資料

[1] 本專案 HW2_report_template.md：本次實驗設定、模型結果與 OLS 診斷。
[2] 本專案 README.md：資料切分、部署方式與研究限制。
[3] Suraj Wate, Regression with a Flood Prediction Dataset. https://surajwate.com/blog/regression-with-a-flood-prediction-dataset/
[4] Suraj Wate, S4E5-Flood-Prediction-Dataset. https://github.com/surajwate/S4E5-Flood-Prediction-Dataset
[5] B. N. Oreshkin, S. Tavker, D. Efimov, Probabilistic Pretraining for Neural Regression. https://arxiv.org/abs/2508.16355v1
[6] AutoGluon AWESOME.md (Gitee mirror), S4E5 solution index. https://gitee.com/mirrors/autogluon/blob/master/AWESOME.md
[7] S. Tiwari, From Baseline to Top 10%: A Practical Kaggle Competition Playbook. https://uselessai.in/from-baseline-to-top-10-a-practical-kaggle-competition-playbook-702d1d9394f8
[8] KartikeyBartwal, Flood-Estimation-Kaggle-Competition. https://github.com/KartikeyBartwal/Flood-Estimation-Kaggle-Competition
[9] Udacity, Cross Validation in Machine Learning: Techniques and Best Practices. https://www.udacity.com/blog/cross-validation-in-machine-learning-techniques-and-best-practices/

附錄 A：重現方式與檔案說明

環境與執行

```
python -m venv .venv
.\.venv\Scripts\python.exe -m pip install -r requirements.txt
.\.venv\Scripts\python.exe main.py
.\.venv\Scripts\python.exe -m pytest -q
```

主要檔案

- 5115056040_hw2.py：學號命名的作業入口。
- main.py 與 src/：完整可重現分析程式。
- outputs/figures/ 與 outputs/tables/：本報告使用的真實輸出。
- report/predict_the_flood_hw2_report.md：原始 NotebookLM 匯出。
- report/predict_the_flood_hw2_report_edited.md：經整理與校訂版本。
- 5115056040_hw2.pdf：本正式報告。

自動化驗收

專案測試涵蓋 schema、metrics、Pipeline leakage guard、Python/JavaScript prediction parity、interval contract 與網站必要資產。正式打包前再次執行 pytest，並檢查 PDF 可開啟、頁數、圖片清晰度與 ZIP 清單。